

6_朴素贝叶斯

朴素贝叶斯法是基于贝叶斯定理与特征条件独立假设的分类方法。

6_1_朴素贝叶斯法的学习与分类

训练数据集

$$T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$$

由 $P(X, Y)$ 独立同分布产生。其中, $\mathbf{x}_i \in \mathcal{X} \subseteq \mathbb{R}^n, y_i \in \mathcal{Y} = \{c_1, c_2, \dots, c_K\}, i = 1, 2, \dots, N$, \mathbf{x}_i 为第 i 个特征向量(实例), y_i 为 \mathbf{x}_i 的类标记, X 是定义在输入空间 \mathcal{X} 上的随机向量, Y 是定义在输出空间 \mathcal{Y} 上的随机变量。 $P(X, Y)$ 是 X 和 Y 的联合概率分布。

条件独立性假设

$$\begin{aligned} P(X = \mathbf{x} | Y = c_k) &= P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)} | Y = c_k) \\ &= \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) \end{aligned}$$

即, 用于分类的特征在类确定的条件下都是条件独立的。

由

$$\begin{aligned} P(X = \mathbf{x}, Y = c_k) &= P(X = \mathbf{x}|Y = c_k) P(Y = c_k) \\ P(X = \mathbf{x}, Y = c_k) &= P(Y = c_k|X = \mathbf{x}) P(X = \mathbf{x}) \end{aligned}$$

得

$$\begin{aligned} P(X = \mathbf{x}|Y = c_k) P(Y = c_k) &= P(Y = c_k|X = \mathbf{x}) P(X = \mathbf{x}) \\ P(Y = c_k|X = \mathbf{x}) &= \frac{P(X = \mathbf{x}|Y = c_k) P(Y = c_k)}{P(X = \mathbf{x})} \\ &= \frac{P(X = \mathbf{x}|Y = c_k) P(Y = c_k)}{\sum_Y P(X = \mathbf{x}, Y = c_k)} \\ &= \frac{P(X = \mathbf{x}|Y = c_k) P(Y = c_k)}{\sum_Y P(X = \mathbf{x}|Y = c_k) P(Y = c_k)} \\ &= \frac{P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k)}{\sum_Y P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k)} \end{aligned}$$

朴素贝叶斯分类器可表示为

$$\begin{aligned} y = f(\mathbf{x}) &= \arg \max_{c_k} \frac{P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k)}{\sum_Y P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k)} \\ &= \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k) \end{aligned}$$

6_2_朴素贝叶斯法的参数估计

6_2_1_极大似然估计

朴素贝叶斯模型参数的极大似然估计

1. 先验概率 $P(Y = c_k)$ 的极大似然估计

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N} \quad k = 1, 2, \dots, K$$

2. 设第 j 个特征 $x^{(j)}$ 可能取值的集合为 $\{a_{j1}, a_{j2}, \dots, a_{jS_j}\}$, 条件概率 $P(X^{(j)} = a_{jl}|Y = c_k)$ 的极大似然估计

$$\begin{aligned} P(X^{(j)} = a_{jl}|Y = c_k) &= \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)} \\ j &= 1, 2, \dots, n; \quad l = 1, 2, \dots, S_j; \quad k = 1, 2, \dots, K \end{aligned}$$

其中, $x_i^{(j)}$ 是第 i 个样本的第 j 个特征; a_{jl} 是第 j 个特征可能取的第 l 个值; I 是指示函数。

朴素贝叶斯算法：

输入：线性可分训练数据集 $T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ ，其中 $\mathbf{x}_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$ ， $x_i^{(j)}$ 是第 i 个样本的第 j 个特征， $x_i^{(j)} \in \{a_{j1}, a_{j2}, \dots, a_{jS_j}\}$ ， a_{jl} 是第 j 个特征可能取的第 l 个值， $j = 1, 2, \dots, n$ ； $l = 1, 2, \dots, S_j$ ， $y_i \in \{c_1, c_2, \dots, c_K\}$ ；实例 \mathbf{x} ；

输出：实例 \mathbf{x} 的分类

1. 计算先验概率及条件概率

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N} \quad k = 1, 2, \dots, K$$

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}$$

$$j = 1, 2, \dots, n; \quad l = 1, 2, \dots, S_j; \quad k = 1, 2, \dots, K$$

2. 对于给定的实例 $\mathbf{x} = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T$ ，计算

$$P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k) \quad k = 1, 2, \dots, K$$

3. 确定实例 \mathbf{x} 的类别

$$y = f(\mathbf{x}) = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)$$

6_2_1_贝叶斯估计

朴素贝叶斯模型参数的贝叶斯估计

1. 条件概率的贝叶斯估计

$$P_\lambda(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}$$

式中 $\lambda \geq 0$ 。当 $\lambda = 0$ 时，是极大似然估计；当 $\lambda = 1$ 时，称为拉普拉斯平滑。

2. 先验概率的贝叶斯估计

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K \lambda}$$